

ETL-система для аналитики СберАвто

Заключительный отчет по проекту

Выполнен: 23.09.2025

Автор: Кононенко Константин

Оглавление

- 0. Фундаментальное исследование данных
- 1. Обзор проекта
- 2. Техническая архитектура
- 3. Результаты обработки данных
- 4. Анализ ключевых показателей (с диаграммами)
- 5. Сравнительный анализ
- 6. Географические сведения (с диаграммой)
- 7. Модели поведения пользователей (с диаграммами)
- 8. Бизнес-рекомендации
- 9. Технические преимущества
- 10. Результаты проекта

0. Фундаментальное исследование данных

АНАЛИЗ БОЛЬШИХ ДАННЫХ (Google Colab — 16,7 млн исторических записей):

МЕТОДОЛОГИЧЕСКИЙ ПОДХОД:

- Комплексный анализ более 1,7 млн сеансов и более 15 млн событий
- 8-месячные исторические данные (май 2021 г. - январь 2022 г.)
- Проверка качества данных и идентификация закономерностей
- Основа для проектирования и профилирования ETL-системы

ОБЛАСТЬ ДАННЫХ:

- История сеансов: 1 744 952 записи
- Исторические просмотры: 14 995 938 записей
- Всего проанализировано: 16 740 890 записей
- Период времени: 8 месяцев активности пользователей

КЛЮЧЕВЫЕ ПОДТВЕРЖДЕННЫЕ ВЫВОДЫ:

- Подтверждена целостность связи между сеансом и попаданием в него (100% надежная связь)
- Установлено доминирование мобильного трафика (базовый показатель 79,3%)
- Выявлены закономерности географической концентрации (Москва: 46% исторической доли)
- Рассчитаны контрольные показатели вовлеченности пользователей (в среднем 9,06 посещений/сеанс)

ОСНОВА ДЛЯ ИНКРЕМЕНТАЛЬНОЙ ОБРАБОТКИ:

Этот масштабный анализ лег в основу проектирования архитектуры ETL.

правил валидации данных и определения критически важных базовых метрик

для точного сравнения тенденций с инкрементальными данными за январь 2022 года.

5 аналитических диаграмм в последующих разделах основаны на этом

комплексном исследовании больших данных, предоставляя проверенные сведения

для текущей реализации системы ETL.

1. Обзор проекта

Цель: создать надежный конвейер ETL для обработки данных Google Analytics.
из JSON-файлов и загрузка в аналитическую базу данных.

Эволюция данных:

- Этап 1: Исторический анализ (16,7 млн записей, 8 месяцев) - Google Colab
- Этап 2: Инкрементная обработка (373 тыс. записей. 4 дня) - Система ETL
- Этап 3: Сравнительный анализ и выявление тенденций

Текущий объем данных:

- 8 файлов JSON, охватывающих 4 дня (2-5 января 2022 г.)
- 34 722 сеанса пользователей
- 338 488 пользовательских событий (попаданий)
- 30 241 уникальный клиент

Технический стек:

- AirFlow: оркестрация workflow
- DuckDB: Аналитическая база данных
- Python: реализация логики ETL
- MD5-хеширование: механизм дедупликации

2. Техническая архитектура

Поток данных:

Файлы JSON -> AirFlow DAG -> Python ETL -> DuckDB -> Аналитика

Проектирование системы основано на:

- Анализе более 1,7 млн исторических сеансов в Google Colab
- Проверке взаимосвязей данных и паттернов
- Тестировании производительности с использованием больших наборов данных

Ключевые компоненты:

1. AirFlow DAG (sberauto_etl_dag)

- задача process_sessions_data
- задача process_hits_data
- задача initialize_database

2. Функции ETL (Python)

- process_json_file_final_csv()
- Дедупликация файлов на основе MD5
- Обработка ошибок и ведение журнала

3. Схема базы данных

- sessions_incremental (18 столбцов)
- hits_incremental (13 столбцов)
- обработанные_файлы (5 столбцов)

3. Результаты обработки данных

УСПЕШНО ОБРАБОТАНО:

Инкрементный объем данных:

- Сеансы: 34 722 записи
- Количество просмотров: 338 488 записей
- Файлы: 8 файлов JSON
- Всего: 373 210 записей

Исторический контекст (из анализа Colab):

- История сеансов: 1 744 952 записи
- Исторические просмотры: 14 995 938 записей
- Всего проанализировано: 16 740 890 записей

Показатели качества данных:

- Уникальность: 100% (без повторяющихся сеансов)
- Полнота: 0 значений NULL в ключевых полях
- Целостность данных: охват сеансов 95,95%

Производительность обработки:

- Время обработки файла: ~30 секунд на 70 тыс. записей
- Размер базы данных: ~200 МБ для 373 тыс. записей
- Эффективное использование памяти: пакетная обработка на основе CSV.

4. Анализ ключевых показателей

АНАЛИЗ ДАННЫХ ЗА ЯНВАРЬ 2022 Г. (4 дня) — полученные в результате исследования больших данных:

Тенденции роста:

- Рост числа сеансов: +30,5% за 4 дня
- Уникальные клиенты: 30 241 пользователь
- Средняя вовлеченность: 9,7 посещений за сеанс

Распределение устройств:

- Мобильные устройства: 92,6% (32 140 сеансов)
- Десктоп: 6,4% (2230 сеансов)
- Планшет: 1,0% (352 сеанса)

Временные закономерности:

- Час пик: 13:00 (1919 сеансов)
- Активный период: 11:00-21:00 (65% суточного трафика)
- Стабильное почасовое распределение

Сравнительный контекст (из исторического анализа):

- Историческая доля мобильных устройств: 79,3% (по сравнению с ростом на 92,6%)
- Историческая вовлеченность: 9,06 посещений/сеанс (против 9,7 дополнительных)

Визуализация ключевых показателей, полученных на основе анализа 16,7 млн исторических записей:

Распределение трафика по типам устройств




Диаграмма 1: Распределение типов устройств (на основе анализа 16,7 млн записей)




Диаграмма 2: Динамика ежедневных посещений (на основе анализа 16,7 млн записей)

5. Сравнительный анализ

СРАВНЕНИЕ ИСТОРИЧЕСКИХ И ДОПОЛНИТЕЛЬНЫХ ДАННЫХ:

Периоды данных:

- Исторический период: май 2021 г. — январь 2022 г. (1,7 млн сеансов, 15 млн просмотров)
- По нарастающей: 2–5 января 2022 г. (34 тыс. сеансов, 338 тыс. просмотров)

Методология:

Анализ использует информацию из 16,7 млн исторических записей, установление надежных ориентиров для измерения постепенных изменений.

Выявлены основные тенденции:

1. Рост мобильного трафика:

- Исторические данные: 79,3% мобильных сеансов
- Инкрементальные данные: 92,6% мобильных сеансов
- Разница: +13,3 процентных пункта

2. Повышение вовлеченности пользователей:

- Исторические данные: 9,06 посещений за сеанс
- Инкрементальные данные: 9,7 обращений за сеанс
- Разница: рост вовлеченности +7%

3. Географическое распространение:

- Более сбалансированное региональное распределение в 2022 году
- Доля Москвы снизилась с 46% до 30%
- Увеличение представительства из других городов России.

6. Географические сведения

АНАЛИЗ ГЕОГРАФИЧЕСКОГО РАСПРЕДЕЛЕНИЯ:

Исторический контекст (из анализа Colab):

- Доминирование Москвы: 46% исторического трафика
- На 10 крупнейших городов пришлось 75% всех сеансов
- Сильная городская концентрация

10 городов по количеству сессий:

1. Москва: 10 531 сеанс (30,3%)
2. Санкт-Петербург: 3695 сеансов (10,6%)
3. Краснодар: 1199 сеансов (3,5%)
4. Екатеринбург: 1060 сеансов (3,1%)
5. Казань: 1006 сеансов (2,9%)
6. Самара: 998 сеансов (2,9%)
7. Уфа: 832 сеанса (2,4%)
8. Новосибирск: 750 сеансов (2,2%)
9. Тула: 743 сеанса (2,1%)
10. Нижний Новгород: 621 сеанс (1,8%)

Региональный охват:

- Представлено более 15 крупных городов России
- 95% трафика из Российской Федерации
- База пользователей, ориентированная на городское население, с более сбалансированным распределением

Географическое распределение на основе комплексного исторического анализа:




Диаграмма 3: 10 крупнейших городов по количеству посещений (на основе анализа 16,7 млн записей)

7. Модели поведения пользователей

АНАЛИЗ ВОВЛЕЧЕННОСТИ ПОЛЬЗОВАТЕЛЕЙ — на основе анализа больших данных:

Историческая база данных (из Colab):

- Средняя продолжительность сеанса: 9,06 событий
- Максимальное количество событий в сеансе: 243
- Стабильные поведенческие модели в течение 8-месячного периода

Характеристики текущего сеанса:

- Средняя продолжительность сеанса: 9,7 событий (рост +7%)
- Максимальное количество событий в сеансе: 243
- Минимальное количество событий: 1
- Среднее количество событий за сеанс: 7

Модели поведения:

- 100% обращений относятся к типу «событие»
- Высокая стабильность вовлеченности в течение дня
- Стабильные паттерны сеансов из часа в час

Технические показатели:

- Охват сеанса: 95,95% сеансов имеют совпадения
- Согласованность данных: 0 пропущенных идентификаторов сеансов
- Временная точность: точная запись временных меток

Модели поведения пользователей, подтвержденные с помощью масштабного исторического анализа:




Диаграмма 4: 10 наиболее частых действий пользователей (на основе анализа 16,7 млн записей)




Диаграмма 5: 10 основных источников трафика по посещениям (на основе анализа 16,7 млн записей)

8. Бизнес-рекомендации

СТРАТЕГИЧЕСКИЕ РЕКОМЕНДАЦИИ — Аналитика на основе данных:

1. ОПТИМИЗАЦИЯ ДЛЯ МОБИЛЬНЫХ УСТРОЙСТВ

- Приоритет: улучшение пользовательского опыта мобильных устройств
- Обоснование: 92,6% трафика с мобильных устройств (рост +13,3%)
- Действие: Разработка мобильных приложений, адаптивный дизайн

2. ОПТИМИЗАЦИЯ ЧАСА ПИК

- Приоритет: выделение ресурсов на 11:00-21:00
- Обоснование: 65% ежедневного трафика в этом окне
- Действие: Масштабирование сервера, поддержка персонала

3. ГЕОГРАФИЧЕСКИЙ ФОКУС

- Приоритет: рынки Москвы и Санкт-Петербурга
- Обоснование: 41% всего трафика из этих городов
- Действие: локализованный маркетинг, региональные акции

4. МОНИТОРИНГ РОСТА

- Приоритет: Отслеживание тенденций роста мобильного трафика
- Обоснование: за 7 месяцев отмечен рост на 13,3%.
- Действие: Непрерывная аналитика, анализ тенденций

5. ОПТИМИЗАЦИЯ ВОВЛЕЧЕНИЯ

- Приоритет: Поддержание и улучшение взаимодействия с пользователями
- Обоснование: рост числа посещений за сеанс на 7%
- Действие: Оптимизация контента, улучшение пользовательского опыта.

9. Технические преимущества

ПРЕИМУЩЕСТВА СИСТЕМЫ — проверено с помощью тестирования больших данных:

Характеристики надежности:

- Идемпотентная обработка: безопасные повторы без дубликатов
- Комплексное ведение журнала: ведется полный контрольный журнал
- Обработка ошибок: постепенное восстановление после сбоя

Оптимизация производительности:

- Пакетная обработка: эффективное использование памяти
- Промежуточный CSV: решение для совместимости с DuckDB
- Пошаговая загрузка: минимальное потребление ресурсов

Готовность к масштабируемости:

- Модульная архитектура: простая замена компонентов
- Оптимизация базы данных: эффективность столбчатого хранения
- Проектирование пайплайна: поддержка горизонтального масштабирования

Преимущества обслуживания:

- Четкий мониторинг: интеграция с пользовательским интерфейсом AirFlow
- Простая отладка: подробные сообщения об ошибках
- Простое развертывание: контейнерная среда

Проверка данных:

- Архитектура проверена на основе 16,7 млн исторических записей
- Правила качества данных проверены на больших наборах данных
- Производительность оптимизирована для корпоративных объемов.

10. Результаты проекта

РЕЗУЛЬТАТЫ ПРОЕКТА — Полный цикл разработки данных:

ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ:

- Полностью функциональный конвейер ETL в AirFlow
- База данных DuckDB с оптимизированной схемой
- Готовая к использованию система обработки данных

АНАЛИТИЧЕСКИЕ ВОЗМОЖНОСТИ:

- Комплексный контроль качества данных
- Формирование аналитических сведений для бизнес-аналитики
- Основы анализа тенденций и отчетности

ЦЕННОСТЬ БИЗНЕСА:

- Система поддержки принятия решений на основе данных
- Масштабируемая аналитическая инфраструктура
- Перспективная техническая основа

МЕТОДОЛОГИЧЕСКИЙ ПОДХОД:

- Основа больших данных: анализ 16,7 млн записей в Google Colab
- Инкрементная обработка: конвейер ETL в реальном времени
- Сравнительная аналитика: исторические и текущие тенденции

СТАТУС СИСТЕМЫ: ГОТОВА К ПРОИЗВОДСТВУ

Система ETL полностью работоспособна и подготовлена для обработки данных в масштабах предприятия, с архитектурой, проверенной посредством комплексного анализа 16,7 млн исторических записей.